

# Técnicas de Amostragem - Aula 01

## Definições e Notações Básicas I: População, Amostra e Planejamento Amostral

---

Kaique Matias de Andrade Roberto

Ciências Atuariais

HECSA - Escola de Negócios

FIAM-FAAM-FMU

1. Conceitos que aprendemos em Aulas anteriores
2. População
3. Amostra
4. Planejamento Amostral
5. Comentários Finais
6. Referências

## **Conceitos que aprendemos em Aulas anteriores**

---

## Conceitos que aprendemos em Aulas anteriores

- recapitulamos os tipos de variáveis;
- aprendemos como classificar variáveis;
- recapitulamos alguns tópicos de Estatística Descritiva;
- relembramos o conceito de Variável Aleatória;
- listamos as principais distribuições discretas e contínuas;
- tivemos um primeiro contato com os conceitos de Amostragem.

# População

---

## Definição 2.1

A **População ou Universo** é o conjunto  $\mathcal{U}$  de todas as unidades elementares de interesse. É indicado por

$$\mathcal{U} = \{1, 2, \dots, N\}$$

onde  $N$  é o tamanho fixo (e na maioria dos casos, desconhecido) da população.

## Definição 2.2

**Elemento Populacional** é a nomenclatura usada para denotar qualquer elemento  $i \in \mathcal{U}$ . É também conhecido por **Unidade Elementar**.

## Definição 2.3

**Característica(s) de Interesse** é a nomenclatura que será usada para denotar a variável ou vetor de informações associado a cada elemento da população. Será representada por

$$Y_i, i \in \mathcal{U},$$

ou no caso multivariado,

$$\mathbf{Y}_i = (Y_{i1}, \dots, Y_{ip}), i \in \mathcal{U}.$$



## Definição 2.4

**Parâmetro Populacional** é a nomenclatura utilizada para denotar o vetor correspondente a todos os valores de uma variável de interesse que denota-se por

$$D = (Y_1, \dots, Y_N),$$

no caso de uma única característica de interesse, e pela matriz

$$D = (Y_1, \dots, Y_N)$$

no caso em que para cada unidade da população tem-se associado um vetor  $Y_i$  de características de interesse.

## Definição 2.5

**Função Paramétrica Populacional** é uma característica numérica qualquer da população, ou seja, uma expressão numérica que condensa funcionalmente os  $Y_i$ 's (ou  $\mathbf{Y}_i$ 's),  $i \in \mathcal{U}$ . Tal função será denotada por

$$\theta(\mathbf{D}).$$

Esta função pode ser, por exemplo, o total, as médias, ou ainda o quociente de dois totais. É comum utilizar-se a expressão parâmetro populacional de interesse, ou simplesmente parâmetro populacional.

## Exemplo 2.6

Considere a população formada por três domicílios  $\mathcal{U}$  e que estão sendo observadas as seguintes variáveis: nome (do chefe), sexo, idade, fumante ou não, renda bruta familiar e número de trabalhadores. Os dados estão na planilha "aula-01-exemplo".

Vamos usar as notações

Unidade	$i$
Nome do Chefe	$A_i$
Sexo	$X_i$
Idade	$Y_i$
Fumante	$G_i$
Renda Bruta Familiar	$F_i$
Número de Trabalhadores	$T_i$

Portanto, para os dados descritos na planilha "aula-01-exemplo", os seguintes parâmetros populacionais podem ser definidos:

- para a variável idade,

$$D = (20, 30, 40) = Y;$$

- para o vetor  $\begin{pmatrix} F_i \\ T_i \end{pmatrix}$  (renda e número de trabalhadores),

$$\begin{pmatrix} 12 & 30 & 18 \\ 1 & 3 & 2 \end{pmatrix}.$$



Com relação às funções paramétricas populacionais, tem-se:

- idade média,

$$\theta(\mathbf{Y}) = \theta(\mathbf{D}) = \frac{20 + 30 + 40}{3} = 30;$$

- média das variáveis renda e número de trabalhadores,

$$\theta(\mathbf{D}) = \begin{pmatrix} \frac{12 + 30 + 18}{1 + 3 + 2} \\ \frac{3}{3} \end{pmatrix} = \begin{pmatrix} 20 \\ 2 \end{pmatrix};$$

- renda média por trabalhador,

$$\theta(\mathbf{D}) = \frac{12 + 30 + 18}{1 + 3 + 2} = 10.$$

Para uma variável de interesse, os parâmetros populacionais mais usados são:

- total populacional,

$$\theta(\mathbf{D}) = \theta(\mathbf{Y}) = \tau = \sum_{i=1}^N Y_i;$$

- média populacional,

$$\theta(\mathbf{D}) = \theta(\mathbf{Y}) = \mu = \bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i;$$

- variância populacional, representada por

$$\theta(\mathbf{D}) = \theta(\mathbf{Y}) = \sigma^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - \mu)^2,$$

ou às vezes,

$$\theta(\mathbf{D}) = \theta(\mathbf{Y}) = s^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \mu)^2.$$



Para vetores bidimensionais, isto é, duas variáveis de interesse, representadas por  $(X, Y)$  são bastante usuais os seguintes parâmetros:

- covariância populacional,

$$\theta(\mathbf{D}) = \sigma_{XY} = \text{Cov}[X, Y] = \frac{1}{N} \sum_{i=1}^N (X_i - \mu_X)(Y_i - \mu_Y);$$

ou às vezes

$$\theta(\mathbf{D}) = s_{XY} = \frac{1}{N-1} \sum_{i=1}^N (X_i - \mu_X)(Y_i - \mu_Y);$$

onde  $\mu_X$  e  $\mu_Y$  denotam as médias populacionais correspondentes às variáveis de interesse  $X$  e  $Y$ , respectivamente;

- correlação populacional,

$$\theta(\mathbf{D}) = \rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y};$$

- razão populacional,

$$\theta(\mathbf{D}) = \frac{\tau_Y}{\tau_X} = \frac{\mu_Y}{\mu_X} = R,$$

- razão média populacional,

$$\theta(\mathbf{D}) = \bar{R} = \frac{1}{N} \sum_{i=1}^N \frac{Y_i}{X_i}.$$

Lembre-se: estas características populacionais **raramente são conhecidas** e na prática, usamos procedimentos amostrais para **estimá-las**.

# Amostra

---

Consideremos uma população fixa

$$\mathcal{U} = \{1, 2, \dots, N\}.$$



## Definição 3.1

Uma sequência qualquer de  $n$  unidades de  $\mathcal{U}$ , é denominada **amostra ordenada** de  $\mathcal{U}$ , isto é,

$$\mathbf{s} = (k_1, \dots, k_n), k_i \in \mathcal{U}.$$

A entrada  $k_i$  é chamada de  **$i$ -ésimo componente** de  $\mathbf{s}$ .

## Exemplo 3.2

Seja  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo"). Os vetores

$$\mathbf{s}_1 = (1, 2)$$

$$\mathbf{s}_2 = (2, 1)$$

$$\mathbf{s}_3 = (1, 1, 3)$$

$$\mathbf{s}_4 = (3)$$

$$\mathbf{s}_5 = (2, 2, 1, 3, 2)$$

são exemplos de amostras ordenadas de  $\mathcal{U}$ .

## Definição 3.3

Seja  $f_i(\mathbf{s})$  a variável que indica o número de vezes (frequência) que a  $i$ -ésima unidade populacional aparece na amostra  $\mathbf{s}$ . Seja  $\delta_i(\mathbf{s})$  a variável binária que indica a presença ou não da  $i$ -ésima unidade na amostra  $\mathbf{s}$ , isto é,

$$\delta_i(\mathbf{s}) = \begin{cases} 1 & \text{se } i \in \mathbf{s}, \\ 0 & \text{se } i \notin \mathbf{s}. \end{cases}$$

## Exemplo 3.4

Seja  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo"). Considere as amostras

$$\mathbf{s}_1 = (1, 2)$$

$$\mathbf{s}_2 = (2, 1)$$

$$\mathbf{s}_3 = (1, 1, 3)$$

$$\mathbf{s}_4 = (3)$$

$$\mathbf{s}_5 = (2, 2, 1, 3, 2)$$

Vamos calcular  $f_i(s_j)$  e  $\delta_i(s_j)$ .

## Definição 3.5

Chama-se **tamanho**  $n(\mathbf{s})$  da amostra  $\mathbf{s}$  a soma das frequências das unidades populacionais na amostra, isto é,

$$n(\mathbf{s}) = \sum_{i=1}^N f_i(\mathbf{s}).$$

## Definição 3.6

Chama-se **tamanho efetivo**  $\nu(\mathbf{s})$  da amostra  $\mathbf{s}$  o número de unidades populacionais na amostra, isto é,

$$\nu(\mathbf{s}) = \sum_{i=1}^N \delta_i(\mathbf{s}).$$

## Exemplo 3.7

Seja  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo"). Considere as amostras

$$s_1 = (1, 2)$$

$$s_2 = (2, 1)$$

$$s_3 = (1, 1, 3)$$

$$s_4 = (3)$$

$$s_5 = (2, 2, 1, 3, 2)$$

Vamos calcular  $n(s_j)$  e  $\nu(s_j)$ .

## Definição 3.8

Seja  $\mathcal{S}(\mathcal{U})$ , ou simplesmente  $\mathcal{S}$ , o conjunto de todas as amostras (sequências ordenadas) de  $\mathcal{U}$ , de qualquer tamanho. E seja  $\mathcal{S}_n(\mathcal{U})$ , a subclasse de todas as amostras de tamanho  $n$ . Muitas vezes,  $\mathcal{S}(\mathcal{U})$  é denominado **espaço amostral**.



## Exemplo 3.9

Seja  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo"). Vamos descrever  $\mathcal{S}(\mathcal{U})$  e  $\mathcal{S}_2(\mathcal{U})$ .

Algumas vezes é interessante trabalhar com amostras não ordenadas (por exemplo, considerar as amostras  $(1, 2)$  e  $(2, 1)$  como sendo as mesmas). No caso de amostras não ordenadas sem reposição, uma amostra é simplesmente um subconjunto de elementos de  $\mathcal{U}$ .

O número de amostras ordenadas de tamanho  $n$ , com reposição, é  $N^n$ , enquanto que, sem reposição, é dado pelo coeficiente binomial  $\binom{N}{n}$ .

# Planejamento Amostral

---

Conforme mencionado anteriormente, um dos nossos objetivos é apresentar procedimentos amostrais probabilísticos, ou seja, aqueles que permitem associar a cada amostra uma probabilidade conhecida de ser sorteada.

O modo como essas probabilidades são associadas é que irá definir um planejamento amostral. Isto nos leva à seguinte definição:

## Definição 4.1

Uma função  $P(\mathbf{s})$  definida em  $\mathcal{S}(\mathcal{U})$ , satisfazendo

$$P(\mathbf{s}) \geq 0, \text{ para quaisquer } \mathbf{s} \in \mathcal{S}(\mathcal{U})$$

e tal que

$$\sum_{\mathbf{s} \in \mathcal{S}(\mathcal{U})} P(\mathbf{s}) = 1,$$

é chamado um **planejamento amostral ordenado**.

## Exemplo 4.2

Considere  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo").  
Considere os seguintes exemplos de planejamentos amostrais:



## Plano A

$$P(11) = P(12) = P(13) = 1/9$$

$$P(21) = P(22) = P(23) = 1/9$$

$$P(31) = P(32) = P(33) = 1/9$$

$$P(\mathbf{s}) = 0, \text{ para as demais } \mathbf{s} \in \mathcal{S}.$$

## Plano B

$$P(12) = P(13) = P(21) = P(23) = P(31) = P(32) = 1/6$$

$P(\mathbf{s}) = 0$ , para as demais  $\mathbf{s} \in \mathcal{S}$ .

## Plano C

$$P(2) = 1/3$$

$$P(12) = P(32) = 1/9$$

$$P(112) = P(132) = P(332) = P(312) = 1/27$$

$$P(111) = P(113) = P(131) = P(311) = 1/27$$

$$P(133) = P(313) = P(331) = P(333) = 1/27$$

$$P(\mathbf{s}) = 0, \text{ para as demais } \mathbf{s} \in \mathcal{S}.$$

## Plano D

$$P(12) = 1/10$$

$$P(21) = 1/6$$

$$P(13) = 1/15$$

$$P(31) = 1/12$$

$$P(23) = 1/3$$

$$P(32) = 1/4$$

$$P(\mathbf{s}) = 0, \text{ para as demais } \mathbf{s} \in \mathcal{S}.$$

## Plano E

$$P(12) = P(32) = 1/2$$

$$P(\mathbf{s}) = 0, \text{ para as demais } \mathbf{s} \in \mathcal{S}.$$

Do exposto anteriormente, constata-se que é possível criar infinitos planejamentos amostrais.

Entretanto, descrever probabilidades associadas a cada amostra passa a ser uma tarefa bastante árdua, principalmente para populações grandes.

Seria muito mais fácil se existissem descrições que permitissem associar, ou calcular, as probabilidades correspondentes a cada amostra de  $\mathcal{S}$ .



Por exemplo, o Plano C poderia ser descrito mais facilmente da seguinte maneira:

Sorteie uma unidade após a outra, repondo a unidade sorteada antes de sortear a seguinte, até o surgimento da unidade 2 ( $i = 2$ ) ou até que 3 unidades tenham sido sorteadas.

Podem ser usados vários tipos de descritores para representar as probabilidades associadas a cada amostra.

Um deles muito utilizado na abordagem clássica da amostragem é a descrição do planejamento através de regras para o sorteio da amostra.

## Exemplo 4.3

Considere  $\mathcal{U} = \{1, 2, 3\}$  (vide planilha "aula-01-exemplo") e a seguinte regra de sorteio:

- i - sorteia-se com igual probabilidade um elemento de  $\mathcal{U}$ , e anota-se a unidade sorteada;
- ii - este elemento é devolvido à população e sorteia-se um segundo elemento do mesmo modo.

Este é o mesmo plano amostral do Plano A. Este plano é conhecido como **amostragem aleatória simples com reposição** (e será detalhado algumas Aulas adiante).

Observa-se que para a maioria dos planejamentos, atribui-se probabilidade nula para muitas amostras de  $\mathcal{S}$ .

Por isso é comum ao apresentar um plano amostral  $A$ , restringir  $\mathcal{S}$  a alguma subclasse  $\mathcal{S}_A$ , contendo apenas as amostras  $\mathbf{s}$ , tais que  $P(\mathbf{s}) > 0$ . Isso facilita bastante a apresentação dos resultados.

É evidente que quanto mais complexas as regras que descrevem os planos amostrais, mais difíceis serão os procedimentos para a determinação das probabilidades associadas ao espaço amostral  $\mathcal{S}$ .



Neste curso serão abordados os planos amostrais mais simples e mais usados, e que servem de base para planos amostrais mais complexos.

Outro conjunto de planos muito úteis e simples, são aqueles de tamanho fixo, ou seja, possuem probabilidades diferentes de zero apenas para a subclasse  $S_n$ .

Os tipos de planejamentos amostrais mais utilizados são:

## Amostragem Aleatória Simples (AAS)

Seleciona-se sequencialmente cada unidade amostral com igual probabilidade, de tal forma que cada amostra tenha a mesma chance de ser escolhida. A seleção pode ser feita com ou sem reposição.

## Amostragem Estratificada (AE)

A população é dividida em estratos (por exemplo, pelo sexo, renda, bairro, etc.) e a AAS é utilizada na seleção de uma amostra de cada estrato.

## Amostragem por Conglomerados (AC)

A população é dividida em subpopulações (conglomerados) distintas (quarteirões, residências, famílias, bairros, etc). Alguns dos conglomerados são selecionados segundo a AAS e todos os indivíduos nos conglomerados selecionados são observados.

Em geral a AC é menos eficiente que a AAS ou AE, mas por outro lado, é bem mais econômica. Tal procedimento amostral é adequado quando é possível dividir a população em um grande número de pequenas subpopulações.

## Amostragem em Dois Estágios (A2E)

Neste caso, a população é dividida em subpopulações como na AE ou na AC. Num primeiro estágio, algumas subpopulações são selecionadas usando a AAS. Num segundo estágio, uma amostra de unidades é selecionada de cada subpopulação selecionada no primeiro estágio.



A AE e a AC podem ser consideradas, para certas finalidades como casos particulares da A2E.

## Amostragem Sistemática (AS)

Quando existe disponível uma listagem de indivíduos da população, pode-se sortear, por exemplo, um nome entre os 10 primeiros indivíduos, e então observar todo décimo indivíduo na lista a partir do primeiro indivíduo selecionado. A seleção do primeiro indivíduo pode ser feita de acordo com a AAS. Os demais indivíduos que farão parte da amostra são então selecionados sistematicamente.

Também serão estudados os estimadores razão e regressão para o total e a média populacionais, que exploram uma possível relação linear entre a variável de interesse  $y$  e alguma variável auxiliar  $x$ , usualmente conhecida como variável independente na teoria de regressão linear.

# Comentários Finais

---

Em resumo, na aula de hoje nós lidamos com uma parte das principais definições, nomenclaturas e terminologias da Teoria de Amostragem. A saber:

- população;
- amostra;
- planejamento amostral.

Nas próximas aulas nós vamos focar na outra parte das nomenclaturas, no caso:

- estatísticas;
- distribuições amostrais;
- estimadores e suas propriedades.

## ATIVIDADE PARA ENTREGAR (E COMPOR A NOTA N1)

Resolva em grupos de até 4 integrantes os Exercícios 1.1, 1.5, 1.7 e 1.10.

## Referências

---







