

# Técnicas de Amostragem - Aula 08

## Amostragem Estratificada I

---

Kaique Matias de Andrade Roberto

Ciências Atuariais

HECSA - Escola de Negócios

FIAM-FAAM-FMU

1. Conceitos que aprendemos em Aulas anteriores
2. Primeiras Definições e Propriedades
3. Notações
4. Estimação do Total e da Média Populacional
5. Alocação da Amostra pelos Estratos
6. Comentários Finais
7. Referências

## **Conceitos que aprendemos em Aulas anteriores**

---

## Conceitos que aprendemos em Aulas anteriores

- definição da AASc e AASs;
- propriedades das principais estatísticas;
- normalidade e intervalo de confiança;
- tamanho da amostra;
- fizemos uma breve introdução aos geradores de números aleatórios.

# **Primeiras Definições e Propriedades**

---

## Definição 2.1

A amostragem **estratificada** consiste na divisão de uma população em grupos (estratos) segundo alguma(s) característica(s) conhecida(s) na população sob estudo, e de cada um desses estratos são selecionadas amostras em proporções convenientes.

A estratificação é usada principalmente para resolver alguns problemas como:

- a melhoria da precisão das estimativas;
- produzir estimativas para a população toda e subpopulações;
- questões administrativas.

Na nossa disciplina focaremos no primeiro motivo: **a melhoria da precisão das estimativas.**



Foi visto (Teorema 4.3 Aula-03) que para uma amostra AASc de tamanho  $n$ , a variância do estimador média amostral  $\bar{y}$ , é dada por

$$\text{Var}[\bar{y}] = \frac{\sigma^2}{n}.$$

Se a população é muito heterogênea e as razões de custo limitam o aumento da amostra, torna-se impossível definir uma AASc da população toda com uma precisão razoável.

Uma saída para esse problema é dividir a população em subpopulações internamente mais homogêneas, ou seja, grupos com variâncias  $\sigma^2$  pequenas que diminuirão o erro amostral global.

## Exemplo 2.2

Considere uma pesquisa feita em uma população com  $N = 8$  domicílios, onde são conhecidas as variáveis renda domiciliar ( $Y$ ) e local do domicílio ( $W$ ), com os códigos  $A$  para região alta e  $B$  para região baixa. Tem-se então,

$$\mathcal{U} = \{1, 2, 3, 4, 5, 6, 7, 8\},$$

com

$$\mathbf{D} = \begin{pmatrix} \mathbf{y} \\ \mathbf{w} \end{pmatrix} = \begin{pmatrix} 13 & 17 & 6 & 5 & 10 & 12 & 19 & 6 \\ B & A & B & B & B & A & A & B \end{pmatrix}$$

Vamos analisar como se comportam os parâmetros de  $\mathbf{D}$  em função dos parâmetros das subpopulações determinadas pelos estratos  $A$  e  $B$ .

O resultado da estratificação será mais eficaz quanto maior for a habilidade do pesquisador em produzir estratos homogêneos.

O caso limite é aquele onde consegue-se a homogeneidade máxima (variância nula dentro de cada estrato) onde então a estimativa acerta o parâmetro populacional.

A simples estratificação por si só não produz necessariamente estimativas mais eficientes que a AAS. O próximo exemplo ilustra tal situação.

## Exemplo 2.3

Considere uma pesquisa feita em uma população com  $N = 8$  domicílios, onde são conhecidas as variáveis renda domiciliar ( $Y$ ) e local do domicílio ( $W$ ), com os códigos  $A$  para região alta e  $B$  para região baixa. Tem-se então,

$$\mathcal{U} = \{1, 2, 3, 4, 5, 6, 7, 8\},$$

divididas nos estratos

$$\mathbf{D}_1 = (13, 17, 6, 5) \text{ e } \mathbf{D}_2 = (10, 12, 19, 6).$$

Vamos analisar como se comportam os parâmetros de  $\mathbf{D}$  em função dos parâmetros das subpopulações determinadas pelos estratos 1 e 2.



A execução de um plano de amostragem estratificada (AE) exige os seguintes passos:

## Passo 1

Divisão da população em subpopulações bem definidas (estratos).

## Passo 2

De cada estrato retira-se uma amostra, usualmente independentes.

## Passo 3

Em cada amostra usam-se estimadores convenientes para os parâmetros do estrato.

## Passo 4

Monta-se para a população um estimador combinando os estimadores de cada estrato, e determinam-se suas propriedades.

# Notações

---

| Estrato  | Dados            | Total    | Média               | Variância               |
|----------|------------------|----------|---------------------|-------------------------|
| 1        | $\mathbf{Y}_1^*$ | $\tau_1$ | $\mu_1 = \bar{Y}_1$ | $\sigma_1^2$ ou $S_1^2$ |
| $\vdots$ | $\vdots$         | $\vdots$ | $\vdots$            | $\vdots$                |
| $h$      | $\mathbf{Y}_h^*$ | $\tau_h$ | $\mu_h = \bar{Y}_h$ | $\sigma_h^2$ ou $S_h^2$ |
| $\vdots$ | $\vdots$         | $\vdots$ | $\vdots$            | $\vdots$                |
| $H$      | $\mathbf{Y}_H^*$ | $\tau_H$ | $\mu_H = \bar{Y}_H$ | $\sigma_H^2$ ou $S_H^2$ |

\* onde  $\mathbf{Y}'_h = (Y_{h1}, \dots, Y_{hN_h})$  é o vetor de dados no estrato  $h$ ,  $h = 1, \dots, H$ .

Vamos definir várias notações envolvendo os dados estratificados como acima. Para exemplificá-las, usaremos os dados à seguir:



# Notações

| Nome     | Categoria | Nota | Nome       | Categoria | Nota |
|----------|-----------|------|------------|-----------|------|
| Enedina  | A         | 10   | Leopoldina | A         | 3    |
| Machado  | A         | 4    | Dandara    | C         | 8    |
| Luiz     | A         | 5    | Francisco  | A         | 6    |
| Marilena | B         | 3    | Felipa     | A         | 7    |
| Clarice  | B         | 9    | Menininha  | C         | 10   |
| Heitor   | B         | 2    | Erenilton  | C         | 9    |
| Camargo  | B         | 8    | Vadinho    | C         | 8    |
| Rita     | B         | 10   | Jorge      | C         | 3    |

Considere uma população bem descrita por um sistema de referências, ou seja,

$$\mathcal{U} = \{1, 2, \dots, N\}$$

e que existe uma partição  $\mathcal{U}_1, \dots, \mathcal{U}_H$  de  $\mathcal{U}$ , ou seja,

$$\mathcal{U} = \bigcup_{h=1}^H \mathcal{U}_h \text{ e } \mathcal{U}_h \cap \mathcal{U}_l = \emptyset$$

se  $h \neq l$ .

Além disso, vamos supor que cada subconjunto  $\mathcal{U}_h$ , bem determinado, é identificado por duplas ordenadas, do seguinte modo:

$$\mathcal{U}_h = \{(h, 1), (h, 2), \dots, (h, N_h)\}.$$

Assim o universo todo pode ser descrito por

$$\mathcal{U} = \{(1, 1), \dots, (h, N_1), \dots, (h, 1), \dots, (h, N_h), \dots, (H, 2), \dots, (H, N_H)\}$$

de modo a facilitar a identificação do estrato e do elemento dentro dele.

De modo análogo, as características populacionais serão identificadas por dois índices, ou seja, no caso univariado, por exemplo, tem-se o vetor de características populacionais

$$\mathbf{D} = (\mathbf{Y}_{11}, \dots, \mathbf{Y}_{1N_1}, \dots, \mathbf{Y}_{h1}, \dots, \mathbf{Y}_{HN_H}),$$

ou seja, para o estrato 1 tem-se as características populacionais  $\mathbf{Y}_{11}, \dots, \mathbf{Y}_{1N_1}$ , e assim por diante.

Eis algumas definições e relações entre os parâmetros:

- Tamanho do estrato  $h$ :  $N_h$ .

- Total do estrato  $h$ :

$$\tau_h = \sum_{i=1}^{N_h} Y_{hi}.$$



- Média do estrato  $h$ :

$$\mu_h = \bar{Y}_h = \frac{1}{N_h} \sum_{i=1}^{N_h} Y_{hi}.$$

- Variância do estrato  $h$ :

$$\sigma_h^2 = \frac{1}{N_h} \sum_{i=1}^{N_h} (Y_{hi} - \mu_h)^2 \text{ ou } S_h^2 = \frac{1}{N_h - 1} \sum_{i=1}^{N_h} (Y_{hi} - \mu_h)^2.$$

- Tamanho do universo:

$$N = \sum_{h=1}^H N_h.$$

- Peso (proporção) do estrato  $h$ :

$$W_h = \frac{N_h}{N} \text{ com } \sum_{h=1}^H W_h = 1.$$

- Total populacional:

$$\tau = \sum_{h=1}^H \tau_h = \sum_{h=1}^H \sum_{i=1}^{N_h} Y_{hi} = \sum_{h=1}^H N_h \mu_h.$$

- Média populacional:

$$\mu = \bar{Y} = \frac{\tau}{N} = \frac{1}{N} \sum_{h=1}^H \sum_{i=1}^{N_H} Y_{hi} = \frac{1}{N} \sum_{h=1}^H N_h \mu_h = \sum_{h=1}^H W_h \mu_h,$$

de modo que a média global é a média ponderada dos estratos.

- Variância Populacional:

$$\sigma^2 = \sum_{h=1}^H W_h \sigma_h^2 + \sum_{h=1}^H W_h (\mu_h - \mu)^2.$$

Também denotamos

$$\sigma^2 = \sigma_d^2 + \sigma_e^2 \text{ com}$$

$$\sigma_d^2 = \sum_{h=1}^H W_h \sigma_h^2 \text{ e } \sigma_e^2 = \sum_{h=1}^H W_h (\mu_h - \mu)^2.$$

- Variância Populacional:

$$S^2 = \sum_{h=1}^H \frac{N_h - 1}{N - 1} S_h^2 + \sum_{h=1}^H \frac{N_h}{N - 1} (\mu_h - \mu)^2.$$



- Para estratos grandes temos

$$S^2 \approx \sigma_d^2 + \sigma_e^2 \approx S_d^2 + \sigma_e^2 \text{ com}$$

$$S_d^2 = \sum_{h=1}^H W_h S_h^2.$$

Note que quando todos os estratos têm a mesma média, ou seja,  $\mu_h = \mu$ ,  $h = 1, \dots, H$ , a variância populacional  $\sigma^2$  coincide com  $\sigma_d^2$ .

Quanto maior for  $\sigma_e^2$ , maior é a diferença  $\sigma^2 - \sigma_d^2$ .

As nomenclaturas para as estatísticas mais usadas (média, total e variância amostrais) são análogas:  $\bar{y}_h$ ,  $T_h$ ,  $s_h^2$  respectivamente.

Lembre que, se  $X_1, X_2, \dots, X_H$  são variáveis aleatórias independentes, então para  $X = \sum_{h=1}^H l_h X_h$ ,

$$E[X] = \sum_{h=1}^H l_h E[X_h] \text{ e } \text{Var}[X] = \sum_{h=1}^H l_h^2 \text{Var}[X_h].$$

# Estimação do Total e da Média Populacional

---

Considere a seguinte situação:

- uma população estratificada;



# Estimação do Total e da Média Populacional

- de cada estrato foi sorteada independentemente uma amostra de tamanho  $n_h$ , podendo ou não ter sido usado o mesmo plano amostral em cada estrato;

- e consideremos  $\hat{\mu}_h$  um estimador não viesado para a média populacional  $\mu_h$  do estrato  $h$ , ou seja,  $E_A[\hat{\mu}_h] = \mu_h$ , onde  $A$  é o plano amostral usado no estrato  $h$ .

## Teorema 4.1

O estimador

$$\bar{y}_{es} = \frac{1}{N} \sum_{h=1}^H N_h \hat{\mu}_h = \sum_{h=1}^H W_h \hat{\mu}_h$$

é não-viesado para a média populacional  $\mu$  e

$$\text{Var}_A[\bar{y}_{es}] = \sum_{h=1}^H W_h^2 \text{Var}_A[\hat{\mu}_h].$$

## Corolário 4.2

Considere agora que, dentro de cada estrato, a amostra foi sorteada por um processo AASc e que  $\hat{\mu}_h = \bar{y}_h$ . Então

$$\bar{y}_{es} = \sum_{h=1}^H N_h \bar{y}_h \text{ e } \text{Var}[\bar{y}_{es}] = \sum_{h=1}^H W_h^2 \frac{\sigma_h^2}{n_h},$$

com estimador não-viesado para  $\text{Var}[\bar{y}_{es}]$  dado por

$$\text{var}[\bar{y}_{es}] = \sum_{h=1}^H W_h^2 \frac{s_h^2}{n_h}.$$

Este procedimento (e sua variante sem reposição) é um dos planos amostrais mais usados em problemas reais.

# **Alocação da Amostra pelos Estratos**

---

## Definição 5.1

A distribuição das  $n$  unidades da amostra pelos estratos chama-se **alocação da amostra**.

Essa distribuição é muito importante pois ela irá garantir a precisão do procedimento amostral.



## Exemplo 5.2

Considere a população  $\mathcal{U} = \{1, 2, 3, 4, 5, 6, 7, 8\}$  do Exemplo 2.1 com a estratificação

$$\mathcal{U}_1 = \{2, 4, 7\} \text{ com } \mathbf{D}_1 = (17, 5, 19)$$

$$\mathcal{U}_2 = \{1, 3, 5, 6, 8\} \text{ com } \mathbf{D}_2 = (13, 6, 10, 12, 6).$$

Vamos estudar o efeito do planejamento (EPA) para duas situações:

1.  $AL_1$ : AASs com  $n_1 = 1$  e  $n_2 = 2$ ;
2.  $AL_2$ : AASs com  $n_1 = 2$  e  $n_2 = 1$ .

Vamos retomar os dados da tabela que usamos para as Notações:

# Alocação da Amostra pelos Estratos

| Nome     | Categoria | Nota | Nome       | Categoria | Nota |
|----------|-----------|------|------------|-----------|------|
| Enedina  | A         | 10   | Leopoldina | A         | 3    |
| Machado  | A         | 4    | Dandara    | C         | 8    |
| Luiz     | A         | 5    | Francisco  | A         | 6    |
| Marilena | B         | 3    | Felipa     | A         | 7    |
| Clarice  | B         | 9    | Menininha  | C         | 10   |
| Heitor   | B         | 2    | Erenilton  | C         | 9    |
| Camargo  | B         | 8    | Vadinho    | C         | 8    |
| Rita     | B         | 10   | Jorge      | C         | 3    |

## Exemplo 5.3

1. Para os estratos A,B,C, realize a alocação  $AL_k$  com uma amostragem AASc com  $n_A = 2$ ,  $n_B = 3$  e  $n_C = 2$ . Para esta alocação, calcule  $Var_{AL_k}[\bar{y}_{es}]$ .
2. Defina uma nova alocação  $AL_e$  de sua preferência e calcule  $Var_{AL_e}[\bar{y}_{es}]$ .
3. Calcule o efeito do planejamento (EPA) entre as alocações  $AL_k$  e  $AL_e$ .

## **Comentários Finais**

---

Em resumo, na aula de hoje nós:

- introduzimos a amostragem estratificada;
- listamos as notações para esse plano amostral;
- falamos da estimação do total e média populacional;
- lidamos com a alocação do tamanho da amostra entre os estratos.

Nas próximas aulas nós vamos continuar focar em:

- tipos de alocação;
- normalidade assintótica e intervalo de confiança;
- tamanho da amostra;
- estimação da proporção.

## EXERCÍCIOS PARA APS (E PREPARAÇÃO PARA A N2)

Resolva os Exercícios 8.1-8.3.



## Referências

---





